Análise de Imagens de Raio-X do Tórax com Filtragem e Segmentação

Chest X-Ray Image Analysis Using Filtering and Segmentation

Mirelle Silva Vieira
Instituto Federal de Educação, Ciência e Tecnologia de Minas Gerais (IFMG)
Bacharelado em Engenharia de Computação

RESUMO

Este trabalho apresenta a utilização de técnicas de filtragem e segmentação para análise de imagens de raio-X do tórax humano, utilizando a linguagem Python. A metodologia utiliza filtros espaciais para reduzir ruídos e aprimorar a visibilidade das estruturas, seguidos pela segmentação para destacar as áreas de interesse. Os resultados obtidos são avaliados por meio das métricas PSNR (Peak Signal-to-Noise Ratio) e SSIM (Structural Similarity Index), visando verificar a eficiência da abordagem proposta na análise de imagens médicas, com potenciais aplicações no suporte ao diagnóstico clínico.

Palavras-chave: Filtragem de Imagens. Segmentação de Imagens. Imagens de Raio-X. Processamento de Imagens Médicas. Diagnóstico por Imagem.

ABSTRACT

This work presents the use of filtering and segmentation techniques for analyzing chest X-ray images using the Python programming language. The methodology applies spatial filters to reduce noise and enhance the visibility of structures, followed by segmentation to highlight regions of interest. The obtained results are evaluated using PSNR (Peak Signal-to-Noise Ratio) and SSIM (Structural Similarity Index) metrics, aiming to verify the efficiency of the proposed approach in medical image analysis, with potential applications in supporting clinical diagnosis.

Keywords: Image Filtering. Image Segmentation. X-ray Images. Medical Image Processing. Diagnostic Imaging.

1 INTRODUÇÃO

Segundo um estudo realizado por Chan et al. (2018), o processamento digital de imagens tem se mostrado uma ferramenta importante na medicina, embora

muitos métodos ainda dependam de processamento manual. A segmentação de imagens e a análise de suas características podem facilitar o diagnóstico e tratamento de doenças, tornando o processo mais rápido e preciso. Contudo, a segmentação de imagens médicas enfrenta dificuldades devido à variação na qualidade das imagens, que depende do equipamento utilizado e das dosagens aplicadas.

Neste trabalho, são utilizados filtros de suavização, como o filtro de Gauss, para reduzir ruídos, e abordagens de segmentação baseadas em limiarização para destacar estruturas relevantes, como os pulmões. A combinação dessas técnicas permite uma análise mais precisa das imagens médicas, com potenciais aplicações no suporte ao diagnóstico clínico.

2 FUNDAMENTOS TEÓRICOS

2.1 Imagens RAW

De acordo com Silva, Patrocínio e Shiabel (2019), as imagens *raw*, ou cruas, são aquelas que não passaram por nenhum tipo de processamento digital e são adquiridas diretamente dos dados obtidos por equipamentos, como os de raios X. Essas imagens, especialmente no contexto da medicina, geralmente não são adequadas para visualização direta e exigem pré-processamento. Esse processamento visa melhorar a qualidade da imagem, corrigir defeitos de pixels, reduzir o ruído e possibilitar o uso de técnicas avançadas de processamento.

2.2 Filtro de Gauss

O Filtro de Gauss tem como objetivo a suavização ou desfocamento da imagem na qual ele é aplicado, visando reduzir os ruídos presentes nela. Este artefato é amplamente utilizado no estágio de pré-processamento de imagem com a finalidade de exibir a estrutura da imagem em diferentes escalas (JESUS, COSTA JR., 2015).

A fórmula da curva de Gauss, representada pela Equação 1, descreve a distribuição normal.

$$G(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \tag{1}$$

Onde:

- x: conjunto com n valores, tal que $-\infty < x < \infty$;
- $G(x)$: distribuição gaussiana dos valores de x;
- σ: desvio padrão dos valores de x, tal que $\sigma > 0$;
- μ: média dos valores de x.

Para a aplicação em filtros gaussianos em imagens bidimensionais, a função gaussiana precisa ser adaptada para considerar as dimensões X e Y da imagem. Essa adaptação é realizada ao multiplicar a equação gaussiana unidimensional (Equação 1) pelas suas versões correspondentes nas dimensões X e Y. O resultado é a Equação 2, que descreve a distribuição gaussiana bidimensional, essencial para o processamento de imagens com o filtro gaussiano.

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \tag{2}$$

2.3 Binarização ou Limiarização

Quanto a análise de objetos em imagens, é fundamental isolar os objetos de interesse do restante da cena, frequentemente tratado como fundo (MARQUES FILHO, 1999). As técnicas utilizadas para essa finalidade são conhecidas como técnicas de segmentação de objetos, cujo objetivo é separar os elementos principais do plano de fundo. Entre essas técnicas, uma das mais utilizadas é a binarização ou limiarização (*thresholding*).

O Algoritmo 1 funciona transformando em branco os pixels com valores iguais ou acima de um determinado limiar e em preto aqueles com valores inferiores a esse limiar (MARQUES FILHO, 1999).

Algoritmo 1 Algoritmo de Binarização

```
for all cada pixel a[m, n] do
    if a[m, n] ≥ θ then
        a[m, n] ← branco
    else
        a[m, n] ← preto
    end if
end for
```

2.4 Métricas

2.4.1 Cálculo do MSE

O MSE (*Mean Squared Error*, ou Erro Quadrado Médio) é definido como o valor médio dos quadrados das diferenças entre os pixels correspondentes das duas imagens (SARA, AKTER, UDDIN, 2019). Para imagens em escala de cinza com di-

mensões $M \times N$, o MSE é calculado pela Equação 3.

$$\text{MSE} = \frac{1}{M \cdot N \cdot O} \sum_{i=1}^{M} \sum_{j=1}^{N} \sum_{z=1}^{O} \left[I(x,y,z) - I'(x,y,z) \right]^2 , \tag{3}$$

onde:

- M e N são as dimensões da imagem (largura e altura);
- O é o número de canais (1 para escala de cinza, 3 para imagens RGB);
- $I(x,y,z)$ é o valor do pixel na imagem original nas coordenadas (x,y) e no canal z;
- $I'(x,y,z)$ é o valor do pixel correspondente na imagem processada.

2.4.2 Cálculo do PSNR

A Relação PSNR (*Peak Signal-to-Noise Ratio*, ou Pico-Sinal-Ruído) é uma métrica amplamente utilizada no processamento de imagens e sinais para avaliar a qualidade de uma imagem processada ou comprimida em relação à imagem original (SETIADI, 2021). O PSNR é baseado no cálculo do erro quadrático médio (MSE), conforme descrito na Equação 4.

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{\text{max}^2}{\text{MSE}} \right) , \tag{4}$$

onde:

- max é o maior valor possível na escala de cinza (por exemplo, 255 para imagens de 8 bits).

Na compressão de imagens e vídeos, a qualidade degradada é avaliada por meio do valor de PSNR. Para dados representados com 8 bits, o PSNR geralmente varia entre 30 e 50 dB, enquanto para dados de 16 bits, o intervalo típico está entre 60 e 80 dB (DESHPANDE, RAGHA, SHARMA, 2018).

2.4.3 Cálculo do SSIM

O SSIM (*Structural Similarity Index Method*, ou Método de Índice de Similaridade Estrutural) é um modelo baseado na percepção. Ele avalia a degradação de imagens como alterações na percepção da informação estrutural, considerando fatores como mascaramento de luminância (onde distorções são menos perceptíveis nas bordas) e mascaramento de contraste (onde distorções são menos visíveis em texturas). O SSIM mede a qualidade percebida de imagens e vídeos, comparando a similaridade entre uma imagem original e sua versão recuperada (SARA, AKTER,

UDDIN, 2019).

A fórmula geral do SSIM está descrita na Equação 5.

$$\text{SSIM}(x, y) = [l(x, y)]^{\alpha} \cdot [c(x, y)]^{\beta} \cdot [s(x, y)]^{\gamma} \tag{5}$$

onde

- $l(x, y)$ mede a similaridade da luminosidade entre duas imagens;
- $c(x, y)$ avalia a diferença nos níveis de contraste;
- $s(x, y)$ compara os padrões estruturais locais das duas imagens.
- α, β e γ são constantes positivas que controlam a contribuição de cada componente no cálculo do SSIM.

Os componentes podem ser definidos como:

$$l(x, y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1}, \quad c(x, y) = \frac{2\sigma_x\sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2}, \quad s(x, y) = \frac{\sigma_{xy} + C_3}{\sigma_x\sigma_y + C_3}$$

onde

- u_x média dos pixels da imagem x;
- u_y média dos pixels da imagem y;
- C_1 constante para estabilizar o cálculo em divisões por valores pequenos;
- σ_x desvio padrão dos pixels da imagem x;
- σ_y desvio padrão dos pixels da imagem y;
- C_2 constante adicional para evitar divisões instáveis;
- σ_{xy} : covariância entre os pixels das imagens x e y;
- C_3 constante para estabilização.

A forma simplificada do SSIM está representada na Equação 6.

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \tag{6}$$

Seu valor varia de 0 a 1, sendo que 1 indica uma imagem idêntica à referência e valores próximos a 1 indicam alta similaridade.

3 METODOLOGIA

3.1 Carregamento e Pré-processamento

Inicialmente, uma imagem foi carregada utilizando a biblioteca OpenCV. Em seguida, aplicou-se um filtro Gaussiano com a função `cv2.GaussianBlur` para suavizar a imagem e reduzir ruídos. Este passo foi essencial para destacar as características relevantes da imagem e facilitar análises subsequentes.

3.2 Exibição de Imagens

Para auxiliar a análise visual, foram desenvolvidas funções em Python para exibir as imagens processadas:

- **Exibição única**: A função `showSingleImage` exibe uma única imagem com título e tamanho definidos pelo usuário;
- **Exibição múltipla**: A função `showMultipleImages` exibe uma única imagem com título e tamanho definidos pelo usuário.

Ambas as funções utilizam a biblioteca Matplotlib para criar uma interface gráfica que facilita a visualização.

3.3 Análise de Qualidade

As métricas de qualidade foram calculadas para comparar a imagem original com a versão suavizada. No código, o **PSNR** é calculado utilizando a função `cv2.PSNR`, que mede a qualidade da imagem em decibéis (dB) comparando a original e a suavizada (após o filtro Gaussiano), com base no **MSE**. Já o **SSIM** foi calculado com a função `compare_ssim` da biblioteca skimage.metrics. Os resultados são exibidos no terminal para indicar a qualidade perceptual e estrutural da imagem processada.

3.4 Segmentação por Limiarização

A segmentação binária foi implementada com uma interface interativa que permite ao usuário ajustar o limiar em tempo real, adaptando-o às suas necessidades:

a) Através da função `cv2.createTrackbar`, foi criado um *trackbar* para controlar o valor do limiar entre 0 e 255;
b) O valor do limiar foi aplicado à imagem utilizando `cv2.threshold`, convertendo-a em uma versão binária (preto e branco);
c) A imagem segmentada foi atualizada dinamicamente com base nos ajustes realizados pelo usuário.

O programa foi estruturado em um loop principal que monitorava continuamente alterações no *trackbar*, processando e exibindo a imagem segmentada apenas quando o valor do limiar era alterado, otimizando recursos computacionais. Além disso, o programa era encerrado de forma segura ao detectar a pressão da tecla ESC, garantindo a liberação adequada dos recursos utilizados.

4 RESULTADOS

4.1 Imagens Processadas

A Figura 1 apresenta a imagem de entrada (original) e a imagem após a aplicação do filtro gaussiano. O filtro gaussiano foi utilizado para reduzir o ruído presente nas imagens, melhorando a visibilidade das estruturas.

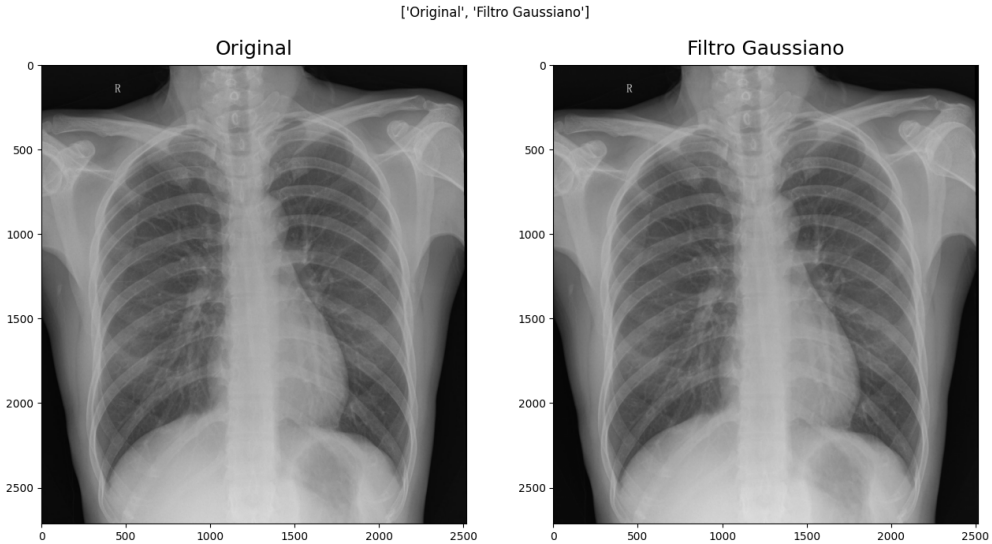

Figura 1 – Imagem antes e após aplicação do Filtro de Gauss

Já a Figura 2 apresenta a imagem segmentada. A segmentação foi aplicada para destacar os pulmões do paciente.

Figura 2 – Imagem segmentada

4.2 Métricas de Qualidade de Imagem

A remoção de ruídos em imagens é uma etapa essencial no processamento digital de imagens, especialmente em aplicações que exigem alta qualidade visual e precisão analítica. Entre as técnicas disponíveis, o filtro de Gauss é amplamente utilizado devido à sua eficiência em suavizar imagens enquanto mantém detalhes importantes.

A Tabela 1 apresenta um resumo dos valores obtidos, demonstrando a eficácia do filtro de Gauss em cada cenário avaliado. O procedimento foi realizado com base em 10 imagens diferentes de 8 bits, obtidas de um dataset contendo radiografias de pessoas diagnosticadas com pneumonia e em condição normal.

Tabela 1 – Resultados após aplicação do filtro de Gauss

Teste	Imagem	Limiar	PSNR (dB)	SSIM
1	NORMAL2-IM-0030-0001.jpeg	130	45.43	0.9874
2	IM-0085-0001.jpeg	145	41.56	0.9723
3	NORMAL2-IM-0060-0001.jpeg	130	45.81	0.9901
4	IM-0095-0001.jpeg	145	44.60	0.9752
5	NORMAL2-IM-0060-0001.jpeg	140	40.22	0.9754
6	IM-0093-0001.jpeg	150	45.02	0.9837
7	NORMAL2-IM-0035-0001.jpeg	145	42.48	0.9827
8	IM-0079-0001.jpeg	135	42.34	0.9720
9	NORMAL2-IM-0359-0001.jpeg	125	41.02	0.9558
10	IM-0045-0001.jpeg	155	37.53	0.9136

A análise estatística dos resultados obtidos revelou as seguintes médias, desvios padrão amostrais e variâncias para as variáveis avaliadas. Para o limiar, a média foi de 140, com desvio padrão amostral de 9,7183 e variância de 94,4444. No caso do PSNR (Peak Signal-to-Noise Ratio), a média observada foi de 42,601, com desvio padrão amostral de 2,6499 e variância de 7,0221. Já para o SSIM (Structural Similarity Index), os valores indicaram uma média de 0,9708, desvio padrão amostral de 0,0224 e variância de 0,0005, refletindo a alta qualidade visual das imagens processadas após a aplicação do filtro de Gauss.

Os valores obtidos para o PSNR (Peak Signal-to-Noise Ratio) e o SSIM (Structural Similarity Index) indicam diferenças sutis entre as duas categorias. Imagens normais geralmente apresentaram maiores valores de PSNR, com destaque para o Teste 3 (PSNR: 45,81 dB) e Teste 1 (PSNR: 45,43 dB), sugerindo menor presença de ruído nas imagens em condições normais após a aplicação do filtro de Gauss. Além disso, o SSIM médio para imagens normais foi ligeiramente maior, com o Teste

3 (SSIM: 0,9901) sendo o mais expressivo, indicando alta similaridade estrutural entre a imagem original e a processada.

Já nas imagens que representam casos de pneumotórax, o PSNR apresentou valores ligeiramente menores, como no Teste 10 (PSNR: 37,53 dB), que apresentou o menor valor entre todos os testes. Esse comportamento pode estar relacionado à maior complexidade visual causada pelas características do pneumotórax, que afeta a eficiência da remoção de ruído pelo filtro de Gauss. No entanto, o SSIM dessas imagens ainda permanece elevado, com valores acima de 0,91, demonstrando que a integridade estrutural foi preservada de forma satisfatória.

4.3 Limitações e considerações finais

Embora os resultados sejam promissores, é importante observar que a qualidade das imagens segmentadas pode ser afetada por fatores como a variação na qualidade das imagens originais e a escolha do limiar de segmentação. Futuras melhorias podem incluir a otimização do processo de segmentação e a aplicação de diferentes técnicas de filtragem para obter resultados ainda mais precisos.

A detecção dos pulmões em imagens médicas, como radiografias de tórax, é essencial para diversas aplicações clínicas. Ela permite identificar e analisar possíveis anomalias, como nódulos, lesões, pneumonias, tuberculose, enfisemas e outras condições pulmonares. Em contextos de diagnóstico assistido por computador, ela também é crucial para automatizar a análise e reduzir o tempo de diagnóstico.

REFERÊNCIAS

CHAN, Yuan-Hao et al. Effective pneumothorax detection for chest X-ray images using local binary pattern and support vector machine. Journal of healthcare engineering, v. 2018, n. 1, p. 2908517, 2018.

DA SILVA, Ana Maria Marques; PATROCÍNIO, Ana Cláudia; SCHIABEL, Homero. Processamento e análise de imagens médicas. REVISTA BRASILEIRA DE FÍSICA MÉDICA (ONLINE), 2019.

DESHPANDE, Renuka G.; RAGHA, Lata L.; SHARMA, Satyendra Kumar. Video quality assessment through PSNR estimation for different compression standards. Indonesian Journal of Electrical Engineering and Computer Science, v. 11, n. 3, p. 918-924, 2018.

JESUS, Edison O.; COSTA JR, Roberto. A utilização de filtros gaussianos na análise de imagens digitais. Proceeding Series of the Brazilian Society of Computational and Applied Mathematics, v. 3, n. 1, 2015.

MARQUES FILHO, O. VIEIRA NETO, H. Processo Digital de Imagens.

Brasport.: Rio de Janeiro, 1999.

SARA, Umme; AKTER, Morium; UDDIN, Mohammad Shorif. Image quality assessment through FSIM, SSIM, MSE and PSNR—a comparative study. Journal of Computer and Communications, v. 7, n. 3, p. 8-18, 2019.

SETIADI, De Rosal Igantius Moses. PSNR vs SSIM: imperceptibility quality assessment for image steganography. Multimedia Tools and Applications, v. 80, n. 6, p. 8423-8444, 2021.